



ANI · Asistente Normativo Institucional

Agente LLM + RAG para la consulta normativa del Liceo Polivalente Guillermo Labarca
Hubertson

Informe técnico · Evaluación Parcial N°1

ISY0101 Ingeniería de Soluciones con IA

Dato	Detalle
Docente	Cristian Cárcamo M.
Estudiantes	Felipe Villalobos · Adolfo Medina
Repositorio	github.com/felipits/ANI-asistente-normativo
Fecha	Octubre de 2026

1. Análisis del caso organizacional

El **Liceo Polivalente Guillermo Labarca Hubertson** (RBD 9985-6, Quinta Normal) es un establecimiento público científico-humanista, técnico-profesional y de adultos, con 552 estudiantes y cerca de un 50 % de población migrante. Desde enero de 2026 depende del SLEP Los Parques. Su normativa está repartida en documentos extensos: el Reglamento de Evaluación y Promoción 2026 (40 págs.), el Reglamento Interno de Convivencia Escolar 2026 con 17 protocolos (194 págs.) y el Decreto 67/2018 del MINEDUC, que rige de forma supletoria.

El conocimiento normativo depende de las personas: UTP atiende cerca de 25 consultas semanales y Convivencia Escolar registró 100 derivaciones en 15 semanas. La respuesta a una misma pregunta varía según a quién se haga, y un error en promoción, plazos o sanciones expone al liceo ante la Superintendencia de Educación. El problema es de **recuperación de información con trazabilidad**: no basta con responder, hay que citar el documento y la página que lo respaldan. De ahí se derivan siete requerimientos:

ID	Requerimiento	Respuesta en ANI
R1	Entender lenguaje cotidiano ("el profe", "un rojo")	Reformulación de consultas, búsqueda semántica y preguntas hipotéticas
R2	Citar documento, ubicación y página verificables	Fragmentos con página exacta y regla de citación en el prompt
R3	No inventar normas: abstenerse si no hay respaldo	Respuestas solo desde fragmentos y re-búsqueda antes de rechazar
R4	Respetar la jerarquía norma interna / Decreto 67	Dos colecciones separadas y regla de supletoriedad (Art. 3°)
R5	Calcular asistencia y plazos en días hábiles	Herramientas de cálculo con feriados de Chile
R6	Proteger datos personales (Ley 21.719)	Corpus solo normativo y ocultamiento de RUT, correo y teléfono
R7	Presupuesto nulo y sin servidor propio	Gemini (plan gratuito), modelos abiertos locales y Google Colab

Los objetivos comprometidos en la propuesta y su resultado en la versión final (v7) son:

Objetivo específico	Meta	Resultado v7
OE1. Indexar el corpus normativo vigente	3 documentos citables	1.142 fragmentos con página exacta ✓
OE2. Citar correctamente documento y página	≥ 90 % de 32 preguntas	96,9 % (31/32) ✓
OE3. Rechazar lo que no está regulado	100 % de 8 preguntas	100 % (8/8), sin falsos rechazos ✓
OE4. Recuperar norma interna y externa juntas	Preguntas mixtas	87,5 % (7/8), parcial

2. Formulación de prompts

El agente usa un **prompt de sistema** en cuatro bloques: (a) rol y contexto, con la fecha del día para calcular plazos; (b) 13 reglas de trabajo; (c) reglas de fundamentación; y (d) formato de salida. Se ejecuta con temperatura 0,2 para privilegiar respuestas estables. Cada técnica responde a un requerimiento del caso:

Técnica	Extracto del prompt	Req.
Rol y contexto temporal	"Eres ANI, el Asistente Normativo Institucional del Liceo... Hoy es {fecha} (hora de Chile)."	R5
Reformulación de la consulta	"Reformula la pregunta con el vocabulario de los reglamentos (ej.: bullying → acoso escolar maltrato entre alumnos)."	R1
Uso obligatorio de herramientas	"Para porcentajes de asistencia o plazos usa SIEMPRE calcular_asistencia o calcular_plazo_habil. Nunca calcules de memoria."	R5
Fundamentación y abstención	"Responde SOLO con la información de los fragmentos... di exactamente: No está regulado en los documentos disponibles."	R3
Citación anclada	"Cita EXACTAMENTE el documento, la ubicación y las páginas del encabezado [F#]. Nunca cites artículos que no aparezcan."	R2
Jerarquía normativa	"El Decreto 67 fija los mínimos... y rige de forma supletoria en lo que el reglamento no regule (Art. 3°)."	R4
Completitud (v3)	"Responde COMPLETO: incluye todos los plazos, requisitos, condiciones, responsables y excepciones."	R2
Formato y público	"Máximo 6 líneas... lenguaje simple para apoderados...  Fuente...  Apoyo informativo: no reemplaza la decisión de UTP."	R6

Como el modelo no siempre sigue las reglas, dos de ellas se aseguran **por código**: si responde sin buscar, se le reenvía la pregunta con un recordatorio; y si va a responder "no está regulado" o "no se especifica", se le obliga a buscar de nuevo con sinónimos formales (nota → calificación, profe → docente). Se usan además dos prompts auxiliares: uno que genera, por fragmento, tres preguntas en lenguaje de apoderado (salida JSON) y otro de **juez** a temperatura 0, que evalúa las respuestas con los criterios de IL1.4.

3. Diseño e implementación del pipeline RAG

Fuente	Tipo	Volumen	Uso
Reglamento de Evaluación y Promoción 2026	Interna	40 págs. → 159 fragm.	Dominio evaluación
Reglamento Interno de Convivencia Escolar 2026	Interna	194 págs. → 932 fragm.	Dominio convivencia
Decreto 67/2018 MINEDUC (BCN)	Externa	9 págs. → 51 fragm.	Norma nacional supletoria

Ingesta (una vez). PyMuPDF extrae el texto y se limpian encabezados, índices y números sueltos. El texto se segmenta según la estructura del documento (título, punto, protocolo, paso o artículo) y cada sección se divide con un divisor recursivo de 800 caracteres y solape de 150, uniendo los trozos de menos de 120 caracteres. Un **mapa línea** → **página** asigna a cada fragmento su página impresa exacta (1,08 páginas por fragmento, frente a 3 a 7 páginas en v1–v5). Gemini genera 3 preguntas hipotéticas por fragmento (3.057 en total, técnica *doc2query*). Los fragmentos se indexan con embeddings multilingual-e5-small en ChromaDB, en dos colecciones (norma interna y externa), y con BM25 para la búsqueda léxica.

Consulta (en cada búsqueda del agente).

1. **Multi-consulta:** se busca con la consulta reformulada por el agente y con la pregunta original del apoderado.
2. **Recuperación híbrida:** tres rankings por consulta (semántico, léxico y por preguntas hipotéticas), filtrados por dominio y fusionados con Reciprocal Rank Fusion.
3. **Reordenamiento:** un cross-encoder multilingüe relee los 20 mejores candidatos; las listas de cada consulta se intercalan y se descartan los fragmentos casi idénticos (similitud > 0,95).
4. **Selección y contexto:** se entregan 4 fragmentos del reglamento elegido más 2 del otro (por si el agente elige mal el dominio), o 4 del Decreto 67. Cada uno se amplía con su sección completa (≤ 2.000 caracteres) o con sus vecinos.
5. **Generación:** el agente recibe los fragmentos con un encabezado [F#] documento · ubicación · página, redacta la respuesta y la cita.

4. Arquitectura de la solución




Figura 1. Arquitectura de ANI: interacción, agente, herramientas, recuperación aumentada e ingesta.

La solución se organiza en cinco capas. La **interacción** usa Gradio, con los colores y logos del liceo, preguntas frecuentes por tema y un filtro que oculta datos personales antes de enviarlos al modelo. El **agente** usa Gemini con *function calling* y memoria por conversación (gemini-3.1-flash-lite como modelo principal, con gemini-flash-latest y gemini-3.5-flash de respaldo ante errores 429 o 503) y decide qué **herramienta** invocar. La **recuperación** es local y gratuita: e5-small, ChromaDB, BM25 y el cross-encoder mmarco-mMiniLMv2. Cada respuesta deja una **traza** visible (búsquedas, fragmentos y cálculos) y puede votarse con 👍/👎 y comentario, lo que alimenta la revisión de UTP. El sistema se ejecuta en Google Colab con GPU T4: la mediana de respuesta es de 19,2 s. El código, los documentos y las evaluaciones están en el repositorio (Villalobos y Medina, 2026).

5. Evaluación y resultados

Se construyó un set de 40 preguntas a partir de las consultas frecuentes de UTP y Convivencia: 24 de un solo dominio, 8 mixtas (cálculo o norma interna y externa) y 8 fuera de alcance. Además de métricas de cita y rechazo, un LLM juez a temperatura 0 calificó exactitud, fidelidad y relevancia y verificó la recuperación (Context Precision, Context Recall y Hit@k con tolerancia de ± 1 página), siguiendo el enfoque de RAGAS (Es et al., 2024).

Ver.	Cambio principal	Exactitud	Context Recall	Hit@k	Context Precision	Rechazo
v1	Prototipo: búsqueda semántica	65,0	62,5	75,0	30,8	100
v2	Búsqueda híbrida y fragmentos de 800	78,8	78,1	81,2	23,7	100
v3	Multi-consulta y reranker	90,0	87,5	84,4	27,8	100
v4	Red léxica que reemplaza resultados	80,0	78,1	87,5	27,5	100
v5	Red léxica como fragmento extra	87,5	84,4	87,5	29,9	100
v6	Páginas exactas, doc2query, padre-hijo	92,5	93,8	96,9	26,2	100
v7	Etiqueta de protocolos y GPU (final)	92,5	93,8	96,9	27,7	100
	Umbral definido por el equipo	80	80	80	50	100

La versión final cumple 6 de 7 criterios, con fidelidad 9,8/10 y relevancia 9,7/10. Context Precision no alcanza el umbral porque el buscador entrega varios fragmentos para no omitir información; una simulación de corte por puntaje mostró que ningún corte llegaba al 50 % sin bajar el recall. Quedan cuatro casos con error: dos de recuperación (#11, acta del PAI; #37, supletoriedad del Decreto 67, donde además se citó un artículo inexistente) y dos de generación (#17, atrasos, y #38, peso de la prueba final). El caso #17 es una regresión: la red léxica de v5 se perdió al reescribir el buscador en v6.

6. Justificación de las decisiones y limitaciones

Búsqueda híbrida. En la versión 1, con solo búsqueda semántica, 12 de los 19 fallos fueron de recuperación: el dato correcto nunca llegaba al modelo, así que ningún ajuste al prompt lo podía arreglar. Combinamos búsqueda semántica con BM25 porque la léxica encuentra frases exactas, como "10 días hábiles", que los embeddings no priorizan. Fusionamos los rankings con Reciprocal Rank Fusion para no tener que calibrar puntajes de escalas distintas.

Reranker. Agregamos un cross-encoder que relee los mejores candidatos. En los casos difíciles recuperó 5 de 6, frente a 3 de 6 sin él (Paso 18). A cambio sube la latencia (la mediana final es de 19,2 s). Lo aceptamos porque para una consulta normativa pesa más la precisión que la rapidez, y porque la GPU del entorno de Colab compensa parte del costo.

Páginas exactas. Antes cada fragmento heredaba el rango de páginas de su sección, que podía llegar a 16, y eso hacía inútil la regla de citación. Con el mapa línea → página cada fragmento tiene en promedio 1,08 páginas, y el Hit@k subió de 87,5 % a 96,9 %. La trazabilidad era el requisito central del caso, así que esta fue la decisión de mayor impacto.

Re-búsqueda obligatoria. El modelo tendía a rendirse con una sola búsqueda. En el caso de "10 días hábiles", la búsqueda con "notas" dejaba el fragmento correcto en el lugar 56, pero con "resultados de las evaluaciones" sí llegaba. Como el prompt por sí solo no garantizaba que el modelo insistiera, lo aseguramos por código: si va a decir "no está regulado", se le

obliga a buscar de nuevo con sinónimos formales. Esto bajó los rechazos falsos sin tocar el rechazo correcto de lo que no está regulado (8/8).

Presupuesto nulo y privacidad. El liceo no tiene presupuesto ni servidor propio, así que usamos modelos locales gratuitos (embeddings, ChromaDB, BM25 y reranker), Gemini en plan gratuito y Google Colab. En privacidad, el corpus es solo normativo y no contiene datos personales, y la interfaz oculta RUT, correo y teléfono antes de enviar la consulta al modelo.

Limitaciones.

- **Dependencia externa:** el sistema depende de Gemini, que nos entregó errores 503 y límites de cuota. Los modelos de respaldo ayudan, pero no eliminan el riesgo.
- **Context Precision:** quedó en 27,7 %, bajo el umbral de 50 %. El buscador entrega varios fragmentos para no omitir información, y en la simulación ningún corte por puntaje llegaba al 50 % sin bajar el recall. Priorizamos no perder información normativa por sobre entregar menos texto.
- **Tamaño del set:** son solo 40 preguntas, por lo que los porcentajes tienen un margen de error amplio y un caso cambia varios puntos.
- **Caso #17 (atrasos):** es una regresión. La red léxica de la v5 se perdió al reescribir el buscador en la v6.
- **Marcas [F#]:** siguen apareciendo en algunas respuestas, lo que afecta la presentación.

7. Conclusiones y reflexiones individuales

Conclusión del equipo

Cumplimos el objetivo general: construimos un asistente que responde consultas sobre la normativa del liceo citando documento y página. De los cuatro objetivos específicos, tres se cumplieron: OE1 (1.142 fragmentos con página exacta), OE2 (96,9 % de citas correctas, sobre la meta de 90 %) y OE3 (100 % de rechazo correcto, sin falsos rechazos). El OE4 quedó parcial, con 87,5 % (7/8) en preguntas que mezclan norma interna y Decreto 67. En total la versión final cumple 6 de 7 criterios de evaluación, con fidelidad de 9,8/10 y relevancia de 9,7/10. El criterio que no cumple es Context Precision.

ANI le aporta al liceo respuestas consistentes, con respaldo verificable, en un tema donde hoy la respuesta depende de a quién se pregunte, y le quita carga a UTP y Convivencia Escolar. Para un piloto real todavía falta que Convivencia y UTP validen las respuestas, ampliar la evaluación (quedaron cuatro casos con error) y resolver la dependencia de un servicio gratuito sujeto a cuota. Mientras tanto, ANI debe usarse como apoyo informativo y no como reemplazo de la decisión de UTP.

Trabajo futuro

- Armar una base de respuestas validadas por Convivencia y UTP.
- Ampliar el set de evaluación con más preguntas.
- Revisar mensualmente los votos 👍 de los usuarios.
- Recuperar la red léxica perdida en la v6, que debería arreglar el caso #17.
- Definir un tiempo máximo de espera ante fallas de Gemini.

Reflexión de Felipe Villalobos

Este proyecto me motivó especialmente por mi rol como profesor jefe, ya que me llegan muchas consultas relacionadas con convivencia escolar. Por eso, ANI cobra especial sentido para mí: podría reducir mi carga laboral y mejorar la especificidad de mis respuestas ante las preguntas de estudiantes y apoderados. Me preocupa que, pese a las distintas iteraciones y ajustes, estos agentes no siempre sean capaces de responder con la precisión requerida. Así ocurrió con la consulta sobre los atrasos, donde ANI respondió que el tema no estaba regulado cuando sí lo estaba en el reglamento. Por lo mismo, es sumamente importante revisar cómo trabajan estos agentes y no dejar todo el trabajo en manos de la inteligencia artificial. Esto también nos enseña que la ingeniería de prompts tiene un límite, y ahí es clave supervisar y resolver con nuestra capacidad humana. Durante el trabajo, mi principal contribución fue el prototipo (P1) del agente y darle una interfaz con carácter institucional, alineada con los colores y símbolos de mi establecimiento, además de mejoras desde la v2 a la v5 (búsqueda híbrida, reranker, re-búsqueda obligatoria, y otros). Para implementar ANI de forma concreta, habría partido por

armar un set previo de preguntas frecuentes de convivencia escolar y UTP, con sus respuestas y justificaciones correctas, para incorporarlas al agente como respuestas validadas y usarlas también para evaluar su desempeño.

Reflexión de Adolfo Medina

Mi aporte principal fue optimizar los chunks y evaluar el funcionamiento del agente. Lo que más me enseñó el proyecto es que en un sistema RAG el problema casi siempre está en la recuperación y no en el modelo: en la v1, más de la mitad de los fallos eran de datos que nunca llegaron al modelo. Eso me hizo entender por qué el tamaño del fragmento (800 caracteres con solape de 150) y su página exacta importan tanto como el prompt.

También aprendí a no confiar en una mejora sin medirla. La red léxica de la v4 empeoró el resultado, y la que se perdió en la v6 dejó la regresión del caso #17. Sin el set de evaluación y las métricas, ninguno de los dos problemas se habría detectado. Si empezara de nuevo, armaría el set de evaluación desde el primer día y lo haría más grande, porque con 40 preguntas cada caso mueve demasiado los porcentajes. Además de lo técnico, me quedo con cómo se distribuyó el trabajo con Felipe: mientras él avanzaba en la arquitectura, yo iba midiendo si cada cambio realmente mejoraba el sistema.

8. Declaración de uso de inteligencia artificial

Se usó **Claude** (Anthropic, 2026) como apoyo para depurar y ordenar el código de los notebooks, estructurar el repositorio y su README, dibujar el diagrama de arquitectura y redactar un borrador de las secciones descriptivas 1 a 5 de este informe. **Gemini** (Google, 2026) es un componente de la solución: actúa como agente, genera las preguntas hipotéticas y sirve de juez en la evaluación. El equipo revisó y validó todo el contenido generado contra los documentos y los resultados de las pruebas. Las secciones 6 y 7 fueron redactadas por el equipo sin IA.

Referencias

- Anthropic. (2026). *Claude* (versión Opus) [Modelo de lenguaje de gran tamaño]. <https://claude.ai>
- Biblioteca del Congreso Nacional de Chile. (2018). *Decreto 67: Aprueba normas mínimas nacionales sobre evaluación, calificación y promoción*. Ministerio de Educación. <https://www.bcn.cl/leychile/navegar?idNorma=1127255>
- Biblioteca del Congreso Nacional de Chile. (2024). *Ley 21.719: Regula la protección y el tratamiento de los datos personales y crea la Agencia de Protección de Datos Personales*. <https://www.bcn.cl/leychile/navegar?idNorma=1209272>
- Bonifacio, L., Jeronymo, V., Abonizio, H. Q., Campiotti, I., Fadaee, M., Lotufo, R., & Nogueira, R. (2021). *mMARCO: A multilingual version of the MS MARCO passage ranking dataset*. arXiv. <https://arxiv.org/abs/2108.13897>
- Cormack, G. V., Clarke, C. L. A., & Büttcher, S. (2009). Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. En *Proceedings of the 32nd International ACM SIGIR Conference* (pp. 758–759). ACM. <https://doi.org/10.1145/1571941.1572114>
- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2024). RAGAS: Automated evaluation of retrieval augmented generation. En *Proceedings of EACL 2024: System Demonstrations* (pp. 150–158). <https://aclanthology.org/2024.eacl-demo.16>
- Google. (2026). *Gemini API: Function calling* [Documentación]. <https://ai.google.dev/gemini-api/docs/function-calling>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.
- Liceo Polivalente Guillermo Labarca Hubertson. (2026a). *Reglamento de Evaluación y Promoción 2026*.
- Liceo Polivalente Guillermo Labarca Hubertson. (2026b). *Reglamento Interno de Convivencia Escolar 2026*.
- Nogueira, R., Yang, W., Lin, J., & Cho, K. (2019). *Document expansion by query prediction*. arXiv. <https://arxiv.org/abs/1904.08375>
- Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333–389.
- Villalobos, F., & Medina, A. (2026). *ANI: Asistente Normativo Institucional* [Código fuente]. GitHub. <https://github.com/felipits/ANI-asistente-normativo>
- Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). *Multilingual E5 text embeddings: A technical report*. arXiv. <https://arxiv.org/abs/2402.05672>